

CAHIER DES CHARGES

GROUPE 7

ANALYSE EXPLORATOIRE DES FACTEURS ASSOCIES AU RISQUE MATERNEL

Projet « Fighting Maternal Risk »

Périmètre du projet

Analyse exploratoire des données de femmes enceintes : exploration, nettoyage, analyse univariée et bivariée, corrélations, croisements par seuils/classes et visualisation. Le notebook exclut explicitement le machine learning du périmètre actuel.

Membres :

Pejuce Pedrich NDINGA
Theresia Surya NGOUBALI
Minervi TULIKUMWE MINDAMUTSA
Eecha Henri MASUKU

1.

a)

Présentation et finalité du projet

Contexte

Dans le cadre du parcours de formation **en Data Science à Akieni Academy**, le projet consiste à réaliser une analyse exploratoire **des facteurs associés aux différents niveaux de risque maternel chez les femmes enceintes**.

Le jeu de données décrit des **mesures de santé de femmes enceintes**, notamment l'âge, la pression artérielle, la glycémie, la température corporelle et la fréquence cardiaque, ainsi qu'un niveau de risque.

b) Problématique

Question centrale

Dans quelle mesure les caractéristiques physiologiques et sociodémographiques des femmes enceintes sont-elles associées aux différents niveaux de risque maternel observés dans les données ?

c) Objectif général

- Décrire les caractéristiques sociodémographiques et physiologiques des femmes enceintes présentes dans les données.
- Étudier leurs relations avec les différents niveaux de risque maternel.
- Mettre en évidence les principales associations observables entre les mesures étudiées et le niveau de risque.

d) Objectifs spécifiques • Charger et documenter les fichiers de données fournis.

- Explorer la structure, la taille, les types, les valeurs manquantes, les doublons et les valeurs suspectes.
- Nettoyer les données sans modifier les fichiers bruts.
- Corriger les anomalies identifiées et créer les variables dérivées prévues.
- Décrire la répartition des trois niveaux de risque.

2.

a)

- Comparer les mesures numériques selon le niveau de risque.
- Mesurer les corrélations entre les variables numériques et le niveau de risque.
- Étudier la relation du risque avec des classes de glycémie et un seuil de tension systolique.
- Produire les huit visualisations prévues.
- Formuler les principaux résultats, limites et recommandations futures.

Périmètre fonctionnel

Inclus dans le périmètre

- Importation des données CSV.
- Exploration descriptive des jeux de données.
- Contrôles de qualité des données.
- Nettoyage et préparation des données.
- Analyse univariée.
- Analyse bivariée.
- Analyse des médianes par niveau de risque.
- Analyse des corrélations.
- Croisement de la glycémie par classes avec le risque.
- Croisement de la tension systolique selon le seuil de 140 mmHg avec le risque.
- Production et sauvegarde des graphiques.
- Synthèse des résultats et des limites.

b) Périmètre

- Aucun modèle de machine learning dans le notebook actuel.
- Aucune prédiction du risque pour de nouvelles patientes dans le périmètre actuel.
- Aucune démonstration de causalité entre une mesure et le risque.
- Aucune validation clinique des seuils dans le notebook.
- Aucune généralisation automatique des résultats à d'autres populations.

Point important

Le notebook mentionne le machine learning, des variables supplémentaires, une analyse temporelle et une validation externe uniquement comme recommandations pour des travaux futurs ; ces éléments ne font donc pas partie des fonctionnalités à réaliser dans ce cahier des charges.

3.

a)

Données et sources

Fichiers attendus

Fichier	Variable pandas	Rôle dans le projet
train.csv	df_train	Jeu principal : mesures de santé + niveau de risque.
test.csv	df_test	Même structure de mesures, sans RiskLevel ; utilisé pour comparer train/test.
sample_submission.csv	df_sample	Vérification du format de réponse attendu ; intérêt analytique marginal.
metadata.csv	df_metadata	Dictionnaire des variables et de leur description.

b) Variables documentées

Variable	Description issue du notebook	Traitement / usage
Id	Identifiant unique de ligne	Conservé ; utilisé pour vérifier unicité et doublons.
Age	Âge de la femme enceinte (années)	Variable d'analyse.
SystolicBP	Pression artérielle systolique (mmHg)	Variable d'analyse + seuil ≥ 140 mmHg.
DiastolicBP	Pression artérielle diastolique (mmHg)	Variable d'analyse.
Blood glucose	Glycémie (mmol/L)	Renommée BloodGlucose ; variable d'analyse + classes.
BodyTemp	Température corporelle ; metadata annonce °C	Conservée ; supposée en °F dans le notebook.
HeartRate	Fréquence cardiaque (bpm)	Variable d'analyse ; contrôle des valeurs < 40 bpm.
RiskLevel	Cible: Low / Mid / High Risk	Codée 0/1/2 dans df_train ; mapping textuel créé comme hypothèse.

4.**a)**

Usage	Indique Train/Test	Supprimée après vérification car constante dans chaque fichier.
--------------	--------------------	---

c) Structure attendue observée

Jeu	Dimensions observées	Constat
df_train	811 × 9	Jeu principal avant nettoyage.
df_test	203 × 8	Sans RiskLevel.
df_sample	203 × 2	Id + RiskLevel textuel.
df_metadata	8 × 2	Dictionnaire des variables.
df_train_clean	809 × 10	Après nettoyage et ajout des variables dérivées.
df_test_clean	203 × 8	Nettoyé de manière cohérente avec train ; sans cible.

4. Environnement technique

Composant	Usage dans le notebook
Python	Langage d'analyse.
pandas	Chargement, nettoyage, transformation, statistiques descriptives, groupby, corrélations et tableaux croisés.
matplotlib	Graphiques : barres, histogrammes, boxplots, nuages de points.
seaborn	Carte de chaleur des corrélations.
os	Gestion des dossiers et sauvegarde des fichiers.

5. Spécifications fonctionnelles détaillées

○ Étape 1 : Introduction et chargement

- 1) Présenter le contexte, la problématique et les objectifs.
- 2) Présenter les quatre fichiers d'entrée et leur rôle.
- 3) Importer os, pandas, matplotlib.pyplot et seaborn.
- 4) Activer l'affichage de toutes les colonnes pandas.
- 5) Charger **train.csv**, **test.csv**, **sample_submission.csv** et **metadata.csv** depuis `./donnees/brutes/`.
- 6) Confirmer que les fichiers ont été chargés avec succès.

○ Étape 2 : Exploration des données

- Afficher le dictionnaire des variables via `metadata.csv`.
- Contrôler les dimensions de tous les datasets.

- Afficher les premières lignes de train, test, sample_submission et metadata.
- Rechercher les valeurs manquantes dans train et test.
- Examiner la répartition de RiskLevel.
- Vérifier les identifiants dupliqués dans train.
- Vérifier les identifiants communs entre train et test.
- Vérifier l'égalité des identifiants test/sample_submission et leur ordre.
- Identifier les lignes identiques hors Id.
- Rechercher les fréquences cardiaques anormalement basses.
- Examiner les valeurs de BodyTemp.

Résultats d'exploration à conserver

Aucune valeur manquante n'est observée. Deux valeurs de HeartRate valent 7 bpm. BodyTemp varie entre 98 et 103 et est traitée comme une température en Fahrenheit malgré l'indication °C du metadata. Les identifiants train sont uniques, aucun Id n'est commun à train et test, et test/sample_submission ont les mêmes Id dans le même ordre.

○ Étape 3 : Nettoyage des données

Objet	Règle obligatoire du notebook	Résultat attendu
Copie	Créer df_train_clean et df_test_clean à partir des originaux.	Les données brutes restent intactes.
Usage	Supprimer Usage.	Colonne absente des jeux nettoyés.
Blood glucose	Renommer Blood glucose en BloodGlucose.	Nom sans espace.
HeartRate	Supprimer les lignes avec HeartRate < 40 bpm.	2 lignes supprimées ; train passe de 811 à 809 lignes.
Température	Créer BodyTemp_C = (BodyTemp - 32) × 5/9, arrondie à 1 décimale.	Colonne BodyTemp_C ajoutée ; BodyTemp originale conservée.
Risque	Créer RiskLabel via 0→Low Risk, 1→Mid Risk, 2→High Risk.	Libellé lisible ; correspondance explicitement considérée comme hypothèse.
Doublons hors Id	Conserver les lignes identiques lorsque les Id sont différents.	396 lignes identiques hors Id dans le train nettoyé.
Index	Réinitialiser l'index de df_train_clean.	Index propre.
Sauvegarde	Créer ./donnees/traitees/ et enregistrer les CSV nettoyés.	train_clean.csv et test_clean.csv.

○ Étape 4 : Analyse des données

Variables numériques étudiées

- Age
- SystolicBP
- DiastolicBP
- BloodGlucose

- BodyTemp_C
- HeartRate

○ Analyse univariée

- Calculer les proportions des niveaux Low Risk, Mid Risk et High Risk.
- Conserver l'ordre d'affichage : Low Risk → Mid Risk → High Risk.

Niveau	Proportion observée
Low Risk	39,9 %
Mid Risk	33,3 %
High Risk	26,8 %

○ Analyse bivariée

- Calculer la moyenne de chaque variable numérique selon RiskLabel.
- Calculer la médiane de chaque variable numérique selon RiskLabel.
- Calculer les corrélations entre les six variables numériques et RiskLevel.
- Classer les corrélations avec le risque de la plus forte à la plus faible.
- Créer une variable GlycemieClasse avec les intervalles 7 ou moins, 7 à 9, 9 à 12 et Plus de 12.
- Croiser GlycemieClasse et RiskLabel en pourcentage par ligne.
- Créer TensionElevee selon SystolicBP ≥ 140 .
- Croiser TensionElevee et RiskLabel en pourcentage par ligne.

○ Résultats analytiques de référence du notebook

Variable	Corrélation avec RiskLevel	Lecture retenue dans le notebook
BloodGlucose	0,56	Modérée-forte ; première association observée.
SystolicBP	0,40	Modérée.
DiastolicBP	0,34	Modérée.
Age	0,27	Faible à modérée.
BodyTemp_C	0,17	Faible.
HeartRate	0,17	Faible.

○ Seuils et croisements à produire

Analyse	Catégories	Résultat observé
Glycémie × risque	≤ 7 ; 7–9 ; 9–12 ; > 12 mmol/L	Au-delà de 9 mmol/L, le High Risk devient majoritaire ; >12 mmol/L : 89,4 % High Risk.
Tension systolique × risque	<140 ; ≥ 140 mmHg	À ≥ 140 mmHg : 95,2 % High Risk, 4,8 % Mid Risk, 0 % Low Risk.

6. Spécifications des visualisations

N°	Visualisation	Objectif	Sortie attendue
1	Répartition des niveaux de risque	Montrer les effectifs des trois classes.	Diagramme en barres.
2	Distribution de chaque mesure	Observer la distribution des six variables numériques.	Histogrammes.
3	Chaque mesure selon le niveau de risque	Comparer les distributions entre Low/Mid/High.	Boîtes à moustaches.
4	Risque selon la classe de glycémie	Visualiser les proportions de risque par classe de glycémie.	Barres empilées en %.
5	Carte des corrélations	Visualiser les corrélations entre variables numériques et risque.	Heatmap seaborn.
6	Glycémie et tension systolique	Voir la combinaison de glycémie et pression par niveau de risque.	Nuage de points coloré par risque.
7	Âge vs Glycémie	Examiner la séparation des niveaux selon âge et glycémie.	Nuage de points coloré par risque.
8	Comparaison train/test	Comparer les distributions de Age et BloodGlucose.	Deux histogrammes comparatifs.

○ Exigences graphiques communes

- Chaque graphique doit comporter un titre explicite.
- Les axes doivent être nommés.
- Les graphiques doivent être affichés avec `plt.show()`.
- La palette utilisée dans le notebook associe Low Risk au vert, Mid Risk à l'orange et High Risk au rouge.
- Les figures sont enregistrées dans le dossier **./figures/**
- Le notebook prévoit notamment une sauvegarde haute résolution pour les graphiques enregistrés.

7) Livrables attendus

Livrable	Contenu / critère
Notebook d'analyse	Notebook exécutable présentant les six grandes sections : Introduction, Exploration, Nettoyage, Analyse, Visualisation, Conclusion.

train_clean.csv	Dataset train nettoyé et enrichi selon les règles du notebook.
test_clean.csv	Dataset test nettoyé selon les règles applicables.
Figures	Les huit visualisations prévues, sauvegardées dans ./figures/
Conclusion analytique	Résumé des résultats, principaux résultats, limites et recommandations futures.

8) Organisation des répertoires

Répertoire / fichier	Fonction
./donnees/brutes/	Source des quatre CSV d'entrée.
./donnees/traitees/	Sortie des datasets nettoyés.
./figures/	Sortie des graphiques.
analyse_risque_maternel.ipynb	Notebook principal d'analyse.

9) Critères de recette et d'acceptation

1. Les quatre fichiers bruts sont chargés depuis **./donnees/brutes/**
2. Les dimensions initiales sont vérifiées et documentées.
3. Aucune valeur manquante n'est introduite lors du nettoyage.
4. Les deux lignes dont HeartRate < 40 sont supprimées du train.
5. df_train_clean contient 809 lignes après nettoyage.
6. Usage est supprimée des jeux nettoyés.
7. Blood glucose est renommée BloodGlucose.
8. BodyTemp_C est créée selon la conversion Fahrenheit → Celsius utilisée dans le notebook.
9. RiskLabel est créée selon la correspondance 0/1/2 documentée comme hypothèse.
10. Les doublons hors Id sont conservés.
11. Les datasets nettoyés sont sauvegardés dans **./donnees/traitees/**
12. Les six variables numériques sont analysées par moyenne, médiane et corrélation.
13. Les quatre classes de glycémie sont analysées en croisement avec RiskLabel.
14. Le seuil SystolicBP ≥ 140 mmHg est analysé.
15. Les huit graphiques sont produits.

16. La conclusion restitue les principaux résultats et les limites sans transformer une association en causalité.

10) Qualité, hypothèses et points de vigilance

○ Hypothèses explicitement présentes dans le notebook

- La correspondance RiskLevel : 0 = Low Risk, 1 = Mid Risk, 2 = High Risk n'est pas donnée par metadata.csv ; elle est utilisée comme hypothèse, notamment parce que les moyennes de glycémie et de tension augmentent avec le code.
- BodyTemp est supposée être exprimée en °F car ses valeurs sont comprises entre 98 et 103 ; elle est convertie en °C dans BodyTemp_C.
- Les lignes identiques hors Id correspondent à des patientes différentes partageant les mêmes mesures ; elles sont donc conservées.

○ Limites de l'étude à restituer

17. Nature observationnelle : seules des associations peuvent être établies, pas des relations de cause à effet.
18. Biais potentiel : les données proviennent de zones rurales du Bangladesh, ce qui limite la généralisation.
19. Variables absentes : parité, IMC, antécédents médicaux et autres facteurs potentiellement pertinents.
20. Données transversales : absence de suivi longitudinal des patientes.
21. Classification du risque : critères exacts de classification non documentés.
22. La corrélation de Pearson appliquée à une variable de risque ordonnée 0/1/2 fournit une indication approximative.
23. L'âge varie de 10 à 70 ans dans les données et ces valeurs extrêmes n'ont pas été vérifiées.
24. La température est très répétitive, avec 98 °F pour environ 80 % des lignes selon la conclusion du notebook.

Règle d'interprétation

Les résultats doivent être formulés comme des associations observées dans le dataset. Ils ne doivent pas être présentés comme des diagnostics médicaux, des seuils cliniques validés ou des relations causales.

11) Évolutions futures mentionnées par le notebook

25. Développer une approche prédictive avec un modèle de machine learning.
26. Ajouter des variables telles que la parité, l'IMC et les antécédents médicaux.
27. Mettre en place un suivi longitudinal des grossesses.
28. Effectuer une validation externe sur d'autres populations.

29. Faire valider les seuils identifiés par des experts médicaux.

Ces évolutions sont hors périmètre du présent cahier des charges ; elles constituent uniquement la feuille de route suggérée par le notebook.

12) Synthèse opérationnelle**Définition synthétique du projet**

Le projet doit produire une analyse exploratoire reproductible du risque maternel à partir de `train.csv`, complétée par les vérifications de `test.csv`, `metadata.csv` et `sample_submission.csv`. Le travail doit explorer la qualité des données, appliquer le nettoyage défini dans le notebook, analyser les relations entre six mesures numériques et les trois niveaux de risque, puis restituer les résultats sous forme de huit graphiques et d'une conclusion argumentée.

Bloc	Exigence principale	Statut attendu
Données	4 fichiers chargés et documentés	Obligatoire
Exploration	Structure, manquants, doublons, anomalies, cible	Obligatoire
Nettoyage	2 anomalies supprimées + transformations prévues	Obligatoire
Analyse	Univariée + bivariée + corrélations + seuils/classes	Obligatoire
Visualisation	8 graphiques	Obligatoire
Sauvegarde	<code>train_clean.csv</code> + <code>test_clean.csv</code> + figures	Obligatoire
ML	Aucun dans le périmètre actuel	Exclu
Conclusion	Résultats + limites + recommandations futures	Obligatoire